

Projeto 2: Quantização de Cores com Redes SOM e GNG

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Gabriel Bonavina (RA: 168.858)

Repositório: <https://github.com/gbonavina/projeto-2-rna>

Configuração Experimental

Este trabalho analisa a compressão e redução do espaço de cores de cinco imagens digitais por meio de dois paradigmas clássicos de aprendizado competitivo não supervisionado: os Mapas Auto-Organizáveis de Kohonen (*Self-Organizing Maps* – SOM) e o *Growing Neural Gas* (GNG). Em ambos os modelos, o problema é formulado de maneira equivalente: cada pixel no espaço de cores RGB é tratado como um vetor de entrada $\mathbf{x} \in [0, 1]^3$. Ao término do treinamento, o conjunto de protótipos (pesos sinápticos) converge para o *codebook* da paleta quantizada, e a imagem reconstruída é obtida associando-se cada pixel ao protótipo de menor distância euclidiana:

$$c(\mathbf{x}) = \arg \min_i \|\mathbf{x} - \mathbf{w}_i\|_2 \quad (1)$$

O conjunto de dados, disponível no diretório `data/`, é composto por fotografias de alta resolução: quatro com dimensões originais de 4032×3024 pixels (`image1`, `image2`, `image4` e `image5`) e uma de 4032×2268 pixels (`image3`). Visando a padronização experimental e viabilidade computacional, todas as imagens foram convertidas para RGB e redimensionadas para 450×450 pixels através de reamostragem com filtro Lanczos, gerando $N = 202\,500$ amostras por imagem. A complexidade espectral resultante varia entre 55 122 cores distintas em `image5` e 88 833 em `image4`.

A reprodutibilidade foi garantida fixando a semente pseudoaleatória em 42. Foram avaliados codebooks de cardinalidade $K \in \{16, 64, 256\}$, que no caso da SOM correspondem a topologias bidimensionais de 4×4 , 8×8 e 16×16 neurônios. O desempenho foi quantificado por meio de três métricas analíticas:

1. **Erro Médio de Quantização (QE):** distância euclidiana média entre os pixels originais e os respectivos protótipos mais próximos no espaço normalizado $[0, 1]^3$;
2. **Erro Quadrático Médio (MSE):** média das distâncias euclidianas quadradas nos três canais normalizados;
3. **Pico da Relação Sinal-Ruído (PSNR):** expresso em decibéis (dB) por $\text{PSNR} = 10 \log_{10}(1/\text{MSE})$.

Adicionalmente, contabilizou-se a eficiência do uso do codebook mensurando o número de protótipos efetivamente distintos após quantização e arredondamento para a faixa clássica de 8 bits por canal ($[0, 255]$), o que expõe eventuais colapsos de neurônios para tons redundantes.

1. Mapas Auto-Organizáveis (SOM)

O treinamento da SOM baseou-se na biblioteca de aceleração matricial *XPySom*, operando em espaço tridimensional ao longo de 100 épocas completas. A cada época, todos os 202 500 pixels foram apresentados, totalizando $20,25 \times 10^6$ passos de atualização por grade. A taxa de aprendizado inicial $\eta_0 = 0,5$ decaiu exponencialmente até $\eta_N = 0,01$. A dinâmica de vizinhança gaussiana adotou como raio inicial metade da extensão lateral da grade ($\sigma_0 = 2, 4$ e 8 para 4×4 , 8×8 e 16×16 , respectivamente), decaindo monotonicamente até $\sigma_N = 1,0$. A topologia retangular e a largura intrínseca $\text{std} = 0,5$ seguiram as diretrizes padrão da biblioteca.

A escolha de σ_0 assegura uma cobertura ampla no início do processo, forçando unidades adjacentes na grade a convergirem para regiões conexas do espaço de cores e preservando as relações topológicas. Conforme $\sigma \rightarrow 1,0$, o acoplamento lateral enfraquece, permitindo o refinamento individual de cada protótipo.

Table 1: Métricas obtidas com o modelo SOM após quantização para 8 bits.

Imagem	Grade	Erro de Quant.	MSE	PSNR (dB)	Cores Efetivas
image1	4×4	0,0691	$2,45 \times 10^{-3}$	26,10	16
image1	8×8	0,0348	$6,87 \times 10^{-4}$	31,63	64
image1	16×16	0,0194	$2,19 \times 10^{-4}$	36,59	256
image2	4×4	0,0620	$1,76 \times 10^{-3}$	27,54	16
image2	8×8	0,0322	$5,06 \times 10^{-4}$	32,96	63
image2	16×16	0,0175	$1,46 \times 10^{-4}$	38,34	254
image3	4×4	0,0591	$1,52 \times 10^{-3}$	28,18	16
image3	8×8	0,0281	$3,77 \times 10^{-4}$	34,24	63
image3	16×16	0,0152	$1,19 \times 10^{-4}$	39,26	250
image4	4×4	0,0666	$2,05 \times 10^{-3}$	26,88	16
image4	8×8	0,0317	$5,52 \times 10^{-4}$	32,58	63
image4	16×16	0,0169	$1,62 \times 10^{-4}$	37,90	254
image5	4×4	0,0444	$1,07 \times 10^{-3}$	29,72	16
image5	8×8	0,0238	$3,52 \times 10^{-4}$	34,53	64
image5	16×16	0,0132	$1,22 \times 10^{-4}$	39,12	256
Média	4×4	0,0602	$1,77 \times 10^{-3}$	27,68	16,0
Média	8×8	0,0301	$4,95 \times 10^{-4}$	33,19	63,4
Média	16×16	0,0164	$1,54 \times 10^{-4}$	38,24	254,0

A expansão da malha resulta em ganhos substanciais de fidelidade: dobrar a dimensão lateral reduz o erro de quantização aproximadamente pela metade em todos os casos. O PSNR médio ascende de 27,68 dB (16 cores) para 33,19 dB (64 cores) e 38,24 dB (256 cores). Perceptualmente, a quantização com 16 cores introduz artefatos severos de posterização (*color banding*) em gradientes suaves como céus; a configuração com 64 protótipos mitiga grande parte das transições bruscas; por fim, 256 cores proporcionam reconstruções praticamente indistinguíveis do original a olho nu.

A rigidez topológica imposta pelo SOM converte a grade neural em um mapa bidimensional estruturado do espaço de cores da fotografia. Em **image1** (Figura 2), observa-se a transição contínua entre o amarelo solar em um vértice, os tons de azul ao longo da borda superior e sombras escuras no canto oposto. Em contrapartida, essa atração elástica lateral pode provocar o colapso de protótipos em resoluções discretizadas (8 bits): nas configurações 8×8 e 16×16 de **image2**, **image3** e **image4**, o número de cores distintas foi sutilmente inferior ao total de neurônios (e.g., 250 cores para 256 neurônios em **image3**).




Figure 1: Curvas comparativas de desempenho da SOM (PSNR, MSE, erro de quantização e ocupação de cores) em função da dimensão da grade.




Figure 2: Quantização por SOM em **image1** (88 207 cores originais) sob as três configurações de grade, ressaltando o gradiente topológico da paleta resultante.




Figure 3: Quantização por SOM em *image2*: organização contínua dos tons urbanos e aquáticos na grade 16×16 .




Figure 4: Quantização por SOM em *image3*, configuração de maior PSNR entre as grades 16×16 (39,26 dB).




Figure 5: Quantização por SOM em *image4*: separação contínua entre componentes de vegetação, alvenaria e céu.




Figure 6: Quantização por SOM em *image5*: transições entre zonas de sombra, matizes rosados e iluminação dourada.

2. Growing Neural Gas (GNG)

Diferentemente da topologia fixa da SOM, o GNG constrói dinamicamente um grafo adaptativo não restrito a uma dimensão predefinida. O treinamento inicia-se com dois nós conectados aleatoriamente. Para cada vetor apresentado, o nó vencedor (s_1) e seus vizinhos topológicos são atualizados em direção à amostra, reforçando a aresta entre s_1 e o segundo protótipo mais próximo (s_2). Conexões com idade superior a $a_{\max}$ são sistematicamente eliminadas. Periodicamente, a cada λ amostras, uma nova unidade é alocada entre o neurônio com maior erro acumulado e seu vizinho de maior discrepância.

O regime de treino foi executado ao longo de 5 épocas sob amostragem aleatória (1 012 500 iterações). Os hiperparâmetros adotados constam na Tabela 2. Com $\lambda = 2000$, o processo de expansão até 256 nós conclui-se em 508 000 iterações (aproximadamente 50% do orçamento computacional total), reservando a metade restante exclusivamente para a estabilização e ajuste fino dos pesos sinápticos. A constante de decaimento de erro $\beta = 0,99975$ confere uma janela efetiva de memória de $1/(1 - \beta) = 4000$ amostras, integrando o erro acumulado em um intervalo correspondente a duas inserções sucessivas (2λ).

Table 2: Hiperparâmetros empregados no treinamento da rede GNG.

Parâmetro	Valor	Função Operacional
ε_b (<code>lr_winner</code>)	0,05	Taxa de aprendizado da unidade vencedora
ε_n (<code>lr_neighbor</code>)	0,0006	Taxa de aprendizado dos vizinhos topológicos
$a_{\max}$ (<code>max_edge_age</code>)	50	Limiar de idade para remoção de arestas
λ (<code>lambda_steps</code>)	2000	Intervalo de amostragem entre inserções neurais
α	0,5	Fator de atenuação do erro local na inserção
β	0,99975	Taxa de decaimento do erro a cada iteração
Épocas	5	Passagens iterativas sobre o conjunto de pixels

Table 3: Métricas obtidas com o modelo GNG após quantização para 8 bits.

Imagem	Neurônios	Erro de Quant.	MSE	PSNR (dB)	Cores Efetivas
image1	16	0,0636	$1,92 \times 10^{-3}$	27,16	16
image1	64	0,0322	$4,86 \times 10^{-4}$	33,14	64
image1	256	0,0185	$1,53 \times 10^{-4}$	38,16	256
image2	16	0,0550	$1,30 \times 10^{-3}$	28,85	16
image2	64	0,0286	$3,39 \times 10^{-4}$	34,70	64
image2	256	0,0161	$1,08 \times 10^{-4}$	39,68	256
image3	16	0,0518	$1,21 \times 10^{-3}$	29,17	16
image3	64	0,0262	$3,03 \times 10^{-4}$	35,19	64
image3	256	0,0147	$9,36 \times 10^{-5}$	40,29	256
image4	16	0,0541	$1,34 \times 10^{-3}$	28,72	16
image4	64	0,0289	$3,86 \times 10^{-4}$	34,13	64
image4	256	0,0170	$1,34 \times 10^{-4}$	38,73	252
image5	16	0,0399	$7,65 \times 10^{-4}$	31,16	16
image5	64	0,0214	$2,15 \times 10^{-4}$	36,68	64
image5	256	0,0126	$7,28 \times 10^{-5}$	41,38	255
Média	16	0,0529	$1,31 \times 10^{-3}$	29,01	16,0
Média	64	0,0275	$3,46 \times 10^{-4}$	34,77	64,0
Média	256	0,0158	$1,12 \times 10^{-4}$	39,65	255,0

O PSNR médio do GNG evoluiu de 29,01 dB (16 neurônios) para 34,77 dB (64 neurônios) e 39,65 dB (256 neurônios). O aproveitamento do codebook foi praticamente integral: com 16 e 64 unidades, não houve sobreposição cromática; no limite de 256 neurônios, registraram-se apenas perdas residuais em `image4` (252 cores) e `image5` (255 cores). A inserção guiada por densidade e acúmulo de erro evita a concentração excessiva de nós em volumes restritos.

Ao analisar a representação visual da paleta em mosaico, nota-se ausência de ordenamento bidimensional aparente, uma vez que os nós são indexados conforme a ordem de alocação temporal e não projetados em um reticulado euclidiano regular. Contudo, a estrutura intrínseca revela-se quando o próprio grafo é inspecionado (Figura 13): ao projetar os pesos de `image5` via PCA, constata-se que os dois primeiros componentes principais retêm 98,6% da variância total (92,0% em PC1 e 6,6% em PC2). O grafo mapeia a variedade dimensional subjacente de forma coesa, estendendo-se do espectro escuro até os tons quentes de forma contínua, sem conexões espúrias entre extremos cromáticos.




Figure 7: Evolução do desempenho do GNG em função da capacidade do modelo.




Figure 8: Quantização por GNG em **image1**: preservação de componentes cromáticas minoritárias de alta saturação (e.g., o centro do sol) desde 16 protótipos.




Figure 9: Reconstruções via GNG em image2.




Figure 10: Reconstruções via GNG em image3, superando a marca de 40 dB de PSNR com 256 unidades.




Figure 11: Reconstruções via GNG em image4.




Figure 12: Reconstruções via GNG em image5, alcançando o ápice de fidelidade com 41,38 dB.




Figure 13: Topologia do grafo GNG (256 unidades) para `image5`: à esquerda, projeção $R \times G$; à direita, projeção via PCA, evidenciando o alinhamento da malha ao longo da variedade cromática.

3. Análise Comparativa

Ambos os modelos foram submetidos aos mesmos conjuntos de entrada e restritos a tamanhos de codebook idênticos, diferindo fundamentalmente nos princípios de organização topológica. Enquanto a SOM impõe uma geometria rígida prévia sobre a qual projeta os dados, o GNG ajusta localmente a dimensionalidade e conectividade do grafo conforme a distribuição empírica das amostras.

Os resultados compilados na Tabela 4 atestam a superioridade quantitativa consistente do GNG sobre a SOM em todos os 15 cenários avaliados. A vantagem média em PSNR foi de +1,33 dB para 16 cores, +1,58 dB para 64 cores e +1,41 dB para 256 cores. O ganho mais expressivo ocorreu em `image5` com 256 protótipos (+2,26 dB), ao passo que a menor discrepância observou-se em `image4` para 256 unidades (+0,83 dB).

Table 4: Comparação direta de PSNR (dB) entre SOM e GNG em função da capacidade do codebook.

Imagem	16 protótipos		64 protótipos		256 protótipos	
	SOM	GNG	SOM	GNG	SOM	GNG
<code>image1</code>	26,10	27,16	31,63	33,14	36,59	38,16
<code>image2</code>	27,54	28,85	32,96	34,70	38,34	39,68
<code>image3</code>	28,18	29,17	34,24	35,19	39,26	40,29
<code>image4</code>	26,88	28,72	32,58	34,13	37,90	38,73
<code>image5</code>	29,72	31,16	34,53	36,68	39,12	41,38
Média	27,68	29,01	33,19	34,77	38,24	39,65

A hierarquia de complexidade das imagens revelou-se congruente entre as duas redes: `image1` apresentou os maiores índices de erro e menores valores de PSNR em todas as capacidades, reflexo de sua ampla dispersão espectral e transições de iluminação com saturações extremas. Já `image5` apresentou a melhor convergência para ambos os modelos, favorecida por uma distribuição de cores concentrada ao longo de uma variedade quase unidimensional no espaço RGB. Constatou-se ainda que o efeito da dimensão do codebook supera o do algoritmo adotado: uma SOM com 256 unidades (38,24 dB) é nitidamente superior a um GNG com 64 unidades (34,77 dB).

O contraste essencial reside na relação de compromisso (*trade-off*) entre distorção de quantização e interpretabilidade topológica. A restrição rígida da SOM acopla os neurônios de forma a gerar uma

ordenação bidimensional intuitiva e contínua do espectro, porém ao custo de limitar a flexibilidade de aproximação e sub-representar populações cromáticas reduzidas (como evidenciado pelo sol de **image1**, capturado com fidelidade cromática superior pelo GNG com 16 unidades). Além disso, a atração entre vizinhos na SOM induz redundância em discretizações finitas de 8 bits, reduzindo a variabilidade efetiva de protótipos.

Em cenários com codebooks densos (256 cores), ambas as redes produzem aproximações visuais com alta fidelidade perceptiva, tornando a escolha do algoritmo dependente dos requisitos da aplicação: caso o objetivo primordial seja a minimização estrita da distorção com representação acurada de modas isoladas, o GNG destaca-se como a opção superior; caso a estruturação, indexação espacial ou visualização do espectro cromático seja prioritária, a SOM oferece uma topologia inerentemente organizada.